



GROWTH ATLAS

# Investigación de scraping y tubería de datos

Fuentes, cumplimiento, arquitectura de ingestión y diseño del Opportunity Score.

## DECISIÓN CENTRAL

Construir una plataforma de conectores autorizados y evidencia trazable; no un scraper universal basado en evasión.

# Contenido

|                                                          |           |
|----------------------------------------------------------|-----------|
| <b>1. Conclusión ejecutiva</b>                           | <b>3</b>  |
| <b>2. Qué significan realmente los links compartidos</b> | <b>3</b>  |
| <b>3. Tubería recomendada</b>                            | <b>4</b>  |
| <b>4. Fuentes de eventos</b>                             | <b>5</b>  |
| <b>5. X y Google Trends: demanda y tendencias</b>        | <b>6</b>  |
| <b>6. GitHub: actividad técnica real</b>                 | <b>7</b>  |
| <b>7. Geografía y confianza</b>                          | <b>8</b>  |
| <b>8. Contrato de datos y esquema mínimo</b>             | <b>9</b>  |
| <b>9. Opportunity Score recomendado</b>                  | <b>9</b>  |
| <b>10. Conexión con el prototipo actual</b>              | <b>10</b> |
| <b>11. MVP ejecutable</b>                                | <b>11</b> |
| <b>12. Controles operativos y legales</b>                | <b>12</b> |
| <b>13. Decisión final</b>                                | <b>12</b> |

# 1. Conclusión ejecutiva

Growth Atlas es viable, pero no debería construirse como un "scraper gigante" ni apoyarse en VPS, VPN, proxies residenciales, cookies de sesión o resolución automática de CAPTCHA.

La arquitectura sostenible es una plataforma de ingestión con conectores intercambiables:

1. APIs oficiales, datasets y feeds autorizados.
2. Calendarios y eventos aportados por organizadores.
3. Scraping limitado solo cuando los términos y la licencia lo permitan.
4. Evidencia cruda con trazabilidad, normalización y resolución de entidades.
5. Agregados por lugar, tecnología y período, con una confianza visible.
6. Un score explicable, no una cifra generada a partir de datos simulados.

La tubería de la imagen es una buena primera hipótesis, pero le falta una entrada indispensable:

```

Eventos + demanda + actividad técnica
      +
Datos de organizadores y clientes
(precio, capacidad, asistencia, activación, retención)
      ↓
Opportunity Score + Expected ROI
  
```

Sin costos de sponsorship ni resultados postevento, Growth Atlas puede rankear **oportunidad y afinidad**, pero no debe afirmar costo por activación, eficiencia o retorno esperado.

## Decisión recomendada

| Componente                    | Ruta recomendada                                                 | Decisión                          |
|-------------------------------|------------------------------------------------------------------|-----------------------------------|
| Eventos                       | feeds autorizados, organizadores, MLH curado, APIs conectadas    | Construir                         |
| X                             | API oficial, primero Trends/Counts y luego muestras de posts     | Construir                         |
| Google Trends                 | BigQuery ahora; aplicar al API alpha; Keyword Planner como apoyo | Construir con límites geográficos |
| GitHub                        | Innovation Graph + GH Archive + REST/GraphQL                     | Construir                         |
| Camofox/MarkUDown             | fallback aislado para sitios que autoricen automatización        | No usar como columna vertebral    |
| VPS + VPN + cookies de sesión | evasión frágil y contractualmente riesgosa                       | No usar                           |

# 2. Qué significan realmente los links compartidos

## El hilo de Reddit no es sobre Camofox

El [hilo de Reddit](#) enlaza [Scrape-Technology/markudown-mcp](#), no [jo-inc/camofox-browser](#).

El autor dice que MarkUDown usa tres capas: Cheerio, Playwright/Patchright y un navegador propio llamado Abrasio. En los comentarios reconoce que Instagram y X suelen requerir cookies autenticadas (`sessionid` y `auth_token`) y que el sistema rota perfiles, proxies y resuelve CAPTCHA.

Al corte de esta investigación, el wrapper `markudown-mcp` tiene aproximadamente 14 estrellas, 7 commits, un contribuidor y licencia MIT. Es principalmente un cliente del SaaS [api.scrapetechnology.com](#), no el scraper completo. El backend abierto, [MarkUDown Engine](#), es GPL-3.0 y aún depende opcionalmente de Abrasio para algunas capacidades.

**Veredicto:** sirve para un POC controlado, nunca con cuentas personales/importantes ni cookies enviadas a un SaaS sin DPA, política de retención y revisión de subprocessors. No es una dependencia apropiada para el core de Growth Atlas.

## Qué es Camofox

[Camofox Browser](#) es un servidor de navegador anti-detección basado en Camoufox/Firefox. Tiene REST API, sesiones persistentes, proxies, importación de cookies, VNC, snapshots de accesibilidad, screenshots y logging.

Al corte:

- Cerca de 7.6k estrellas, 792 forks y 326 commits.
- Licencia MIT.
- Release visible [v1.11.2](#) del 24 de mayo de 2026.
- Actividad reciente, aunque concentrada en pocos contribuidores.

No es un extractor de Instagram listo para producción. Su macro de Instagram navega a búsqueda por hashtags; no aporta por sí sola un contrato de datos, paginación, deduplicación, esquema estable ni cumplimiento de eliminaciones.

**Veredicto:** puede ser un navegador de fallback para QA o para sitios que permitan automatización. No convierte una extracción prohibida en una extracción autorizada, ni resuelve la deriva de esquemas.

## Cómo leer el artículo de Scrapfly

El [artículo de Scrapfly sobre X](#) muestra una revisión reciente, pero el propio metadata visible indica que el artículo original data de 2023. Su aporte útil es técnico: X cambia tokens, operaciones internas, límites y defensas, por lo que un scraper no oficial tiene mantenimiento continuo.

Sus cifras operativas y su conclusión comercial deben tratarse como afirmaciones del vendedor. La documentación actual de X ya ofrece pago por uso sin suscripción ni gasto mínimo: [US\\$0.005 por Post leído y US\\$0.010 por User leído](#).

Además, los [Términos de X](#) prohíben expresamente crawling o scraping sin consentimiento escrito. Para Growth Atlas, la API oficial es hoy más barata y mucho menos frágil que operar cuentas, proxies y tokens de sesión.

## 3. Tubería recomendada



Cada conector debe poder apagarse sin romper el producto. La política y licencia de acceso también deben ser datos versionados, no una nota perdida en documentación.

## 4. Fuentes de eventos

La realidad incomoda es que ninguna de las cuatro fuentes de la imagen entrega, de forma abierta y estable, un catálogo mundial completo para reutilización comercial.

### Matriz de acceso

| Fuente               | Acceso real en 2026                                                                                                      | Riesgo/limitación                                                                                            | Semáforo          | Uso recomendado                                                            |
|----------------------|--------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------|-------------------|----------------------------------------------------------------------------|
| Luma                 | <a href="#">API oficial</a> por calendario propio, Luma Plus; 200 req/min por calendario, 500 por organización; webhooks | No es API global de discovery; <a href="#">términos</a> exigen interfaces públicamente soportadas            | Amarillo          | conectar calendarios de organizadores; pedir acuerdo para discovery global |
| Meetup               | <a href="#">GraphQL</a> con OAuth; nuevos consumers solo para Meetup Pro y sujetos a aprobación                          | Los <a href="#">términos</a> prohíben extracción comercial/scraping                                          | Amarillo          | API licenciada o partnership, nunca crawler                                |
| Devpost              | listado público y endpoint interno técnicamente accesible                                                                | No hay API pública soportada y los <a href="#">términos</a> prohíben scraping/crawling manual o automatizado | Rojo              | alianza, export del organizador o curación manual                          |
| MLH                  | página oficial de temporadas con datos estructurados                                                                     | No hay API global documentada; uso comercial necesita confirmación                                           | Amarillo          | dataset pequeño curado para MVP; pedir permiso para producción             |
| Eventbrite           | API autenticada para eventos/organizaciones; acceso por ID                                                               | La Search API pública se cerró en 2019; discovery global requiere relación/partner                           | Amarillo          | conectar organizadores o partnership                                       |
| HackerEarth          | APIs oficiales centradas en Assessments/cuentas                                                                          | Sin API pública de discovery; restricciones de reutilización                                                 | Amarillo/Rojo     | acuerdo comercial o eventos aportados                                      |
| DoraHacks            | sin API pública documentada de discovery                                                                                 | WAF y términos que prohíben extracción sistemática/bots                                                      | Rojo              | no scrapear                                                                |
| Unstop               | endpoint JSON público con datos ricos                                                                                    | No documentado ni licenciado como API estable                                                                | Amarillo          | experimento técnico tras confirmación escrita                              |
| Hackathon.com        | páginas públicas                                                                                                         | catálogo irregular y términos restrictivos para reutilización comercial                                      | Rojo              | no depender de esta fuente                                                 |
| Ticketmaster         | <a href="#">Discovery API v2</a> global, 5.000 llamadas/día                                                              | fuerte para eventos comerciales, débil para hackathons pequeños; máximo práctico de 1.000 items por consulta | Verde             | cobertura urbana complementaria, particionada por fecha/lugar              |
| PredictHQ            | <a href="#">Events API</a> licenciada, con rank/asistencia/gasto estimado                                                | pago, cobertura según plan y derechos de redistribución a negociar                                           | Verde contractual | candidato a backbone de producción si el precio cierra                     |
| pretalx / Sessionize | API o feeds habilitados por cada organizador                                                                             | no existe índice global y el contenido conserva derechos propios                                             | Verde autorizado  | alta precisión para eventos conectados                                     |

### Fuentes más sostenibles

- Organizadores:** formulario o portal para publicar evento, precio, capacidad, audiencia, sponsorship y resultados históricos.
- Calendarios conectados:** Luma API/webhooks, Meetup OAuth, Eventbrite OAuth, ICS y RSS cuando el organizador los proporciona.
- Fuentes por evento:** [pretalx API](#) y feeds de Sessionize cuando el evento los habilita.
- Dataset licenciado:** evaluar agregadores comerciales como PredictHQ solo cuando el alcance y el presupuesto lo justifiquen.
- Curación inicial:** 50-200 eventos con link, fecha, ciudad y evidencia, sin copiar descripciones completas ni datos personales.

## Campos normalizados para Event

```
event_id, canonical_url, title, start_at, end_at, timezone,
venue_type, venue_name, city_id, lat, lon, geo_confidence,
organizer_id, organizer_url, capacity, expected_attendance,
tech_tags[], audience_tags[], sponsor_names[], sponsor_open,
prize_value, currency, application_deadline, source,
source_record_id, observed_at, last_verified_at, evidence_ids[]
```

## Deduplicación

El mismo evento puede aparecer en Luma, Meetup, una universidad y el sitio del organizador. Usar:

```
fingerprint = normalized_title + local_start_date + city_id + organizer_domain
```

Después, resolver candidatos con similitud de título, solapamiento temporal, lugar y dominio. Nunca sobrescribir silenciosamente: conservar todas las evidencias y elegir un registro canónico.

# 5. X y Google Trends: demanda y tendencias

## X: usar API oficial y una estrategia counts-first

La [X API](#) ofrece:

- Recent Search: últimos 7 días, hasta 100 Posts por solicitud.
- Full-Archive Search: desde marzo de 2006, hasta 500 Posts por solicitud.
- Recent/All Counts: volumen por intervalo sin descargar el texto.
- Trends por WOEID: tendencias localizadas por país, región o ciudad.
- Precio por uso, sin suscripción ni mínimo.

[Busqueda oficial](#) y [precios](#).

Flujo recomendado:

1. Consultar Trends por WOEID cada 6 horas para las ciudades objetivo.
2. Filtrar contra una taxonomía de tecnologías y problemas en inglés, español y portugués.
3. Ejecutar Post Counts para cada bundle tecnología-ciudad.
4. Descargar Posts solo cuando el conteo sea anómalo y solo en una muestra necesaria para clasificar intención.
5. Agregar y minimizar texto/identidad; procesar cambios o eliminaciones.

Consultas iniciales:

```
("AI agent" OR "agente de IA" OR MCP OR RAG) -is:retweet
```

```
("looking for" OR "need a tool" OR "busco una herramienta" OR "preciso de uma ferramenta")
("agent observability" OR "agent evals" OR "LLM tracing")
-is:retweet -is:reply
```

```
("looking for sponsors" OR "buscamos sponsors" OR "patrocinadores")
(hackathon OR meetup) -is:retweet
```

Los operadores geográficos solo recuperan Posts que realmente tienen geo. Esa muestra es pequeña y no aleatoria. Una ciudad mencionada en el texto no es automáticamente el origen del autor; `user.location` tampoco es residencia verificada.

La [Developer Policy de X](#) permite heat maps agregados, pero prohíbe separar y almacenar geodatos de forma independiente o seguir individuos. El mapa debe mostrar agregados, cobertura y confianza, nunca movimientos o perfiles personales.

## Costo orientativo de un piloto X

Con precios al 13-jul-2026:

| Operación     | Supuesto mensual                              | Costo aproximado   |
|---------------|-----------------------------------------------|--------------------|
| Trends WOEID  | 50 ciudades x 4/día x 30 x US\$0.01           | US\$60             |
| Recent Counts | 25 ciudades x 40 bundles x 30 x US\$0.005     | US\$150            |
| Muestras      | 10 anomalías/día x 100 Posts x 30 x US\$0.005 | US\$150            |
| <b>Total</b>  | sin User expansions                           | <b>US\$360/mes</b> |

Es un escenario de prueba, no una cotización. Los precios pueden cambiar y deben validarse en Developer Console.

## Google Trends

El [API oficial de Google Trends](#) sigue en alpha limitada y acepta solicitudes de acceso. Ofrece cinco años de datos, intervalos regulares, regiones/subregiones y una escala consistente entre solicitudes.

Mientras llega el acceso:

- El [dataset oficial en BigQuery](#) ofrece Top y Rising terms. Estados Unidos tiene DMA; otros países suelen llegar a país/subregión, no ciudad global.
- [Google Ads Keyword Planner](#) puede validar keywords conocidas con targets geográficos más finos, sujeto a acceso de Google Ads.
- `pytrends` no debe entrar a producción: es no oficial y su repositorio fue archivado en 2025.

Google Trends mide interés de búsqueda relativo, no demanda absoluta ni intención de compra. Un cero puede significar volumen insuficiente; un pico aislado no es una oportunidad sin confirmación independiente.

## Complementos que reducen dependencia de X

| Fuente                                | Señal                                        | Geo                             | Ruta                                   |
|---------------------------------------|----------------------------------------------|---------------------------------|----------------------------------------|
| <a href="#">Hacker News API</a>       | Ask HN, Show HN, jobs, problemas emergentes  | texto explícito solamente       | Verde                                  |
| <a href="#">Bluesky API/Jetstream</a> | conversación técnica en tiempo casi real     | sin geo nativo                  | Verde                                  |
| <a href="#">Stack Exchange API</a>    | preguntas, tags, views y falta de respuestas | sin geo                         | Verde                                  |
| <a href="#">npm downloads</a>         | adopción de paquetes JS                      | sin geo                         | Verde                                  |
| <a href="#">PyPI BigQuery</a>         | releases y descargas Python                  | país como máximo práctico       | Verde                                  |
| <a href="#">Hugging Face API</a>      | modelos/datasets, likes, downloads, trending | sin geo                         | Verde                                  |
| <a href="#">Reddit Data API</a>       | problemas y recomendaciones por comunidad    | subreddit no implica residencia | Solo con aprobación/contrato comercial |

## 6. GitHub: actividad técnica real

GitHub mide oferta, capacidad y preparación técnica. No debe confundirse con demanda o disposición a pagar.

### Orden de fuentes recomendado

1. [GitHub Innovation Graph](#): baseline oficial trimestral por economía y lenguaje, CC0, con supresión de celdas pequeñas y tratamiento de bots.

2. [GH Archive](#): series históricas horarias de actividad pública desde 2011.
3. [REST API](#) y [GraphQL](#): enriquecer repos, lenguajes, topics y usuarios seleccionados.
4. [Search API](#): discovery dividido por fecha/lenguaje para evitar el máximo de 1.000 resultados.
5. [Events API](#): validación reciente; no es un stream completo y cubre alrededor de 30 días y 300 eventos.

Fijar la versión REST `2026-03-10`. El límite normal autenticado es 5.000 solicitudes/hora, con límites secundarios. Search tiene cuotas propias y puede devolver `incomplete_results=true`.

## Métricas útiles

No usar estrellas acumuladas como indicador principal. Para tecnología x lugar x período:

```
Technical Readiness =
  30% crecimiento de desarrolladores humanos activos
+ 20% crecimiento de repos activos no-fork
+ 15% crecimiento de autores/revisores de PR
+ 15% cadencia de releases
+ 10% diversidad de contribuidores
+ 10% velocidad de estrellas
```

Aplicar `log1p`, percentiles o z-score robusto dentro de poblaciones comparables. Reducir bots, mirrors, forks masivos y actividad generada automáticamente.

Separar dos conceptos:

- `technical_readiness`: hay capacidad técnica para adoptar/probar el producto.
- `whitespace`: demanda creciente con presencia reducida de soluciones, siempre que exista un mínimo de readiness.

## Límite geográfico

Innovation Graph ofrece país/economía, no ciudad. La ubicación urbana de `User.location` es libre, opcional y autodeclarada. Puede estar vacía, ser humorística o estar desactualizada.

Reglas:

- País: estable cuando proviene de Innovation Graph.
- Ciudad: etiqueta beta/experimental.
- No inferir ubicación por nombre, email, zona horaria del commit o identidad aparente.
- Mantener desconocido como desconocido.
- Mostrar `location_coverage`, `geocode_confidence` y `n`.
- No exponer usuarios; suprimir celdas pequeñas, idealmente `k >= 100`.

# 7. Geografía y confianza

El mapa no debe transformar una inferencia débil en un hecho. Cada observación necesita método y confianza.

| Método                               | Ejemplo                                | Confianza inicial |
|--------------------------------------|----------------------------------------|-------------------|
| <code>event_explicit_venue</code>    | dirección/ciudad del evento            | 0.95              |
| <code>platform_trend_location</code> | WOEID o Trends subregión               | 0.90              |
| <code>post_explicit_place</code>     | Place adjunto al Post                  | 0.90              |
| <code>organizer_asserted</code>      | organizador conecta su calendario      | 0.90              |
| <code>profile_free_text</code>       | <code>User.location</code> de GitHub/X | 0.40-0.60         |
| <code>text_mention</code>            | ciudad mencionada en el contenido      | 0.20-0.40         |
| <code>none</code>                    | no hay evidencia                       | 0.00              |

Una oportunidad de **ciudad** no debería activarse si solo existe `profile_free_text` o `text_mention`. Debe haber al menos una fuente de geo fuerte y una segunda familia de evidencia independiente.

## 8. Contrato de datos y esquema mínimo

```
source_run
  run_id, source, adapter_version, api_version, terms_version,
  partition, watermark, started_at, ended_at, status,
  record_count, error_count, rate_limit_json, estimated_cost_usd

raw_evidence
  evidence_id, run_id, source_object_id, source_url,
  occurred_at, fetched_at, payload_uri, sha256,
  schema_version, access_method, rights_basis,
  license_policy, expires_at

event
  event_id, canonical_url, title, start_at, end_at, timezone,
  organizer_id, city_id, geo_confidence, capacity,
  tech_tags, sponsor_names, sponsor_open, evidence_ids

place
  place_id, city, admin1, iso2, lat, lon, h3

technology
  tech_id, canonical_name, aliases_by_language, parent_id,
  taxonomy_version

signal
  place_id, tech_id, period, signal_type, metric,
  value, n, coverage, geo_confidence, source_diversity,
  freshness, evidence_ids, model_version

opportunity_score
  place_id, tech_id, period, objective,
  demand_score, technical_score, event_score, gap_score,
  total, confidence, component_json, model_version

campaign_outcome
  client_id, campaign_id, event_id, spend, registrations,
  activated_7d, retained_30d, paid_conversions, revenue
```

IDs de repositorios y actores deben ser los IDs numéricos de GitHub porque sobreviven a renombres. La taxonomía de tecnología debe combinar lenguaje, topics, dependencias y clasificación semántica versionada.

## 9. Opportunity Score recomendado

Primero normalizar cada métrica por fuente, tecnología, período y cohorte geográfica. No sumar volúmenes crudos de X, GitHub y eventos.

```

D = 45% search/trend momentum
  + 35% social count momentum
  + 20% explicit problem intent

T = 30% active developer growth
  + 20% active non-fork repo growth
  + 15% PR/reviewer growth
  + 15% release velocity
  + 10% contributor diversity
  + 10% star velocity

E = 35% technology/audience fit
  + 25% event quality evidence
  + 20% sponsor openness
  + 20% urgency/proximity

G = 100 - competitor/sponsor saturation percentile

```

Para el objetivo **adoption**, un primer prior sería:

```
Base Opportunity = 30% D + 30% T + 25% E + 15% G
```

La confianza debe mostrarse por separado:

```

Confidence = geometric_mean(
  source_coverage,
  source_diversity,
  geographic_confidence,
  freshness,
  sample_sufficiency
)

```

Reglas de publicación:

- Dos familias de fuentes independientes.
- Dos observaciones temporales, no un pico aislado.
- Una fuente con geo fuerte.
- Tamaño de muestra y cobertura visibles.
- Tres evidencias enlazables para explicar la recomendación.
- Si `confidence < 0.55`, mostrar "datos insuficientes", no un ranking preciso.

No incorporar **cost efficiency** hasta tener precio real del organizador o históricos de campañas. Cuando existan resultados, calibrar **Expected ROI** por separado y nunca mezclar datos estimados con observados sin etiqueta.

## 10. Conexión con el prototipo actual

El prototipo ya declara las entidades correctas en `interactive-world-map/lib/atlas-data.ts`, pero los valores son demostrativos y el score agrega ruido determinístico.

Reemplazos recomendados:

| Campo actual                    | Sustitución real                                                       |
|---------------------------------|------------------------------------------------------------------------|
| <code>potential</code>          | percentil de Base Opportunity                                          |
| <code>efficiency</code>         | dejar <code>null</code> hasta tener spend/outcomes; luego Expected ROI |
| <code>events</code>             | cantidad de eventos futuros verificados en ventana                     |
| <code>communityScore</code>     | Technical Readiness con cobertura                                      |
| <code>companiesExploring</code> | sponsor/competitor presence observado                                  |
| <code>costBand</code>           | dato del organizador o claramente <code>estimated</code>               |

| Campo actual                | Sustitución real                                     |
|-----------------------------|------------------------------------------------------|
| topics                      | tabla <code>signal(place_id, tech_id, period)</code> |
| evidence                    | IDs y URLs de <code>raw_evidence</code>              |
| <code>hashNoise(...)</code> | eliminar; usar datos observados y versión del modelo |

La interfaz debe mostrar junto al score:

Score 82 · Confidence 0.71 · updated 6h ago  
3 sources · n=1,420 · city geo coverage 68%

## 11. MVP ejecutable

### Alcance

- 5 ciudades: San Francisco, Buenos Aires, Bangalore, São Paulo y Ciudad de México.
- 3 categorías: agent observability, fine-tuning y vector databases.
- 50-200 eventos curados/autorizados.
- 30-90 días de actividad GitHub/GH Archive y baseline país de Innovation Graph.
- X Trends + Counts; muestras solo para anomalías.
- Google Trends BigQuery; API alpha en paralelo.
- Costos y conversiones simulados solo en una capa de demo claramente marcada.

### Orden de construcción

1. Taxonomía versionada EN/ES/PT.
2. Esquema canónico, raw evidence y source registry.
3. Importador de eventos curados/ICS y formulario de organizador.
4. Innovation Graph + GH Archive + enriquecimiento GitHub.
5. X WOEID/Counts y Google Trends BigQuery.
6. Geografía, deduplicación y agregados diarios.
7. Opportunity Score + Confidence.
8. Sustituir gradualmente los mocks del mapa.

### Criterios de aceptación

- $\geq 95\%$  de runs reproducibles y con lineage.
- Error de parseo  $< 1\%$  en fixtures versionados.
- 0 registros del mapa sin URL/evidencia de origen.
- Duplicados de eventos  $< 5\%$  después de entity resolution.
- `incomplete_results=false` en particiones GitHub Search.
- Coste por fuente y por 1.000 señales medido.
- Cobertura y confianza geográfica visibles.
- Ningún score de ciudad basado solo en texto libre de perfiles.

## 12. Controles operativos y legales

No es asesoramiento legal; antes de producción hace falta revisión de términos, privacidad y licencias para el uso comercial concreto.

Controles mínimos:

- Source registry con `access_method`, URL de términos, fecha/versión, retención y redistribución permitida.
- `rights_basis` obligatorio: `official_api`, `organizer_authorized`, `licensed_aggregator`, `public_feed_with_permission` o `research_only`.
- Respetar `Retry-After`, ETag, cuotas y backoff; nunca evadir límites.
- Jobs de modificación/eliminación, especialmente para X y Reddit.
- Minimizar PII y almacenar agregados siempre que sea posible.
- Secret manager; cookies o tokens nunca en prompts, logs o parámetros visibles.
- Separar raw restringido de tablas analíticas.
- Auditoría de acceso y TTL por fuente.
- DPA y subprocessors para proveedores SaaS.
- Kill switch por conector ante cambio de términos o esquema.

### Lista no-go

- Rotar VPN/VPS para eludir bloqueos.
- Resolver CAPTCHA para acceder a una fuente que rechazó automatización.
- Inyectar cookies personales de X/Instagram en un servicio de terceros.
- Scrapear Devpost, Meetup o X contra sus términos.
- Perfilar o rankear personas individualmente.
- Vender datos personales o ubicaciones de desarrolladores.
- Presentar ubicación inferida como hecho.
- Prometer ROI con costos o retención simulados.

## 13. Decisión final

La tubería correcta no es:

```
VPS + VPN + browser stealth -> scrapear todo
```

Es:

```
fuentes autorizadas + organizadores + evidencia pública agregada
-> normalización y confianza
-> oportunidad explicable
-> outcomes privados
-> ROI calibrado
```

El primer producto defendible es **Hackathon Opportunity Intelligence**, no un scraper universal. El moat no será Camofox, un proxy o un extractor; será el dataset histórico que conecte tecnología + ciudad + evento + inversión con activación y retención reales.